The Web Conference · WWW '24 · Singapore

SimpleDyG

On the Feasibility of Simple Transformer for Dynamic Graph Modeling

Yuxia Wu Yuan Fang Lizi Liao

Nhóm 6: Vũ Duy Thụ & Đỗ Quốc Thịnh

1. INTRODUCTION · BỐI CẢNH

Đồ thị động trong thực tế

Các đỉnh và cạnh xuất hiện và biến đổi liên tục theo thời gian.

Mạng xã hội · UCI

Nút là người dùng, cạnh là tin nhắn; cạnh mới liên tục xuất hiện.

Hệ gợi ý · ML-10M

Người dùng gắn thẻ cho phim theo thời gian.

Mạng trích dẫn · Hội thoại

Bài báo mới trích dẫn bài cũ; các lượt thoại nối tiếp nhau.

ĐỊNH NGHĨA HÌNH THỨC

$$G = (V, E, T, X)$$

cạnh (v_i, v_j, τ), $\tau \in T$

V: tập nút
T: miền thời gian
v_i, v_j: hai nút tương tác

E: tập cạnh (tương tác)
X: đặc trưng đầu vào
τ: thời điểm tương tác

1. INTRODUCTION · VẤN ĐỀ ĐẶT RA

Dynamic Link Prediction

1

Input

Chuỗi cạnh (v_i, v_j, τ), chia thành T time step; lịch sử đến bước T−1 làm đầu vào

↓

2

Model

SimpleDyG (tham số θ)

↓

3

Output

Tập nút liên kết với ego-node tại bước T (dynamic link prediction)

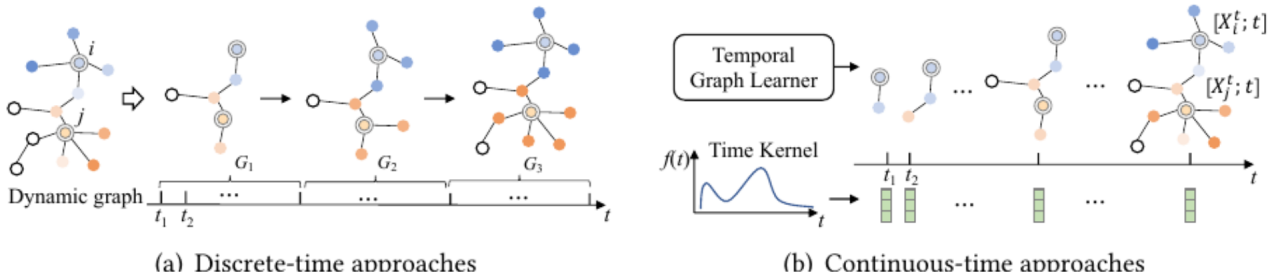
PHÁT BIỂU BÀI TOÁN

Cho trước lịch sử tương tác của nút v_i trước bước thời gian T, dự đoán tập các nút sẽ kết nối với v_i tại bước T:

$$\{ v_i^{T,1} , v_i^{T,2} , \dots \}$$

Chia dữ liệu: T = test · T−1 = validation · còn lại = train **Đánh giá:** NDCG@5, Jaccard

Hai hướng tiếp cận hiện có



(a) Discrete-time approaches (b) Continuous-time approaches

	Discrete-time	Continuous-time
Cách nhìn	Chuỗi snapshot đồ thị	Mỗi tương tác là một sự kiện có timestamp
Module	GNN + RNN/attention (DySAT, EvolveGCN)	Random walk, time encoding, point process (TGAT, TGN, TREND, GraphMixer)
Điểm yếu	Mất hoàn toàn thông tin thời gian chi tiết trong snapshot	Khó nắm bắt phụ thuộc dài hạn

Hạn chế của các phương pháp hiện có

1. Thời gian: thô hoặc ngắn hạn

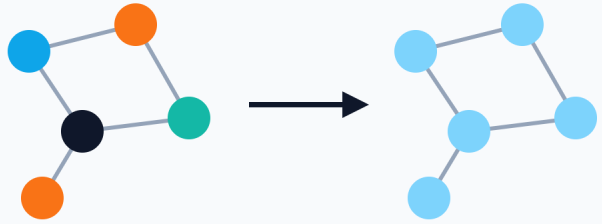
Discrete-time

Bỏ mất thời điểm chi tiết trong snapshot.

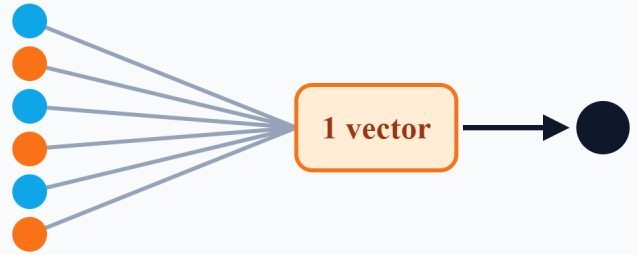
Continuous-time

Giữ chi tiết nhưng khó nhớ lịch sử dài.

2. Hạn chế của message-passing GNN (càng sâu càng nặng)



Over-smoothing: biểu diễn các nút dần trở nên giống nhau.



Over-squashing: thông tin từ vùng lân cận rộng bị nén vào một vector cố định.

Transformer thuần có đủ cho đồ thị động không?

Vì sao chọn Transformer?

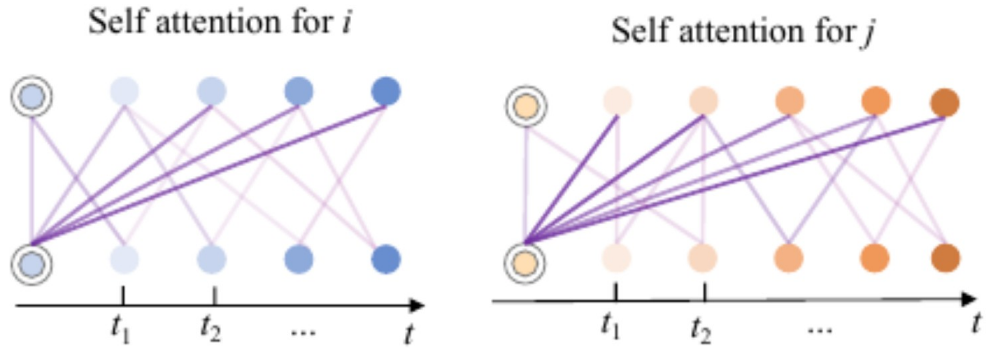
1. Chuỗi liên tục

Nhận trực tiếp chuỗi dữ liệu, không cần chia snapshot rời rạc.

2. Self-attention

Bắt phụ thuộc dài hạn, ít bị over-smoothing và over-squashing hơn.

Transformer gốc, không sửa kiến trúc.



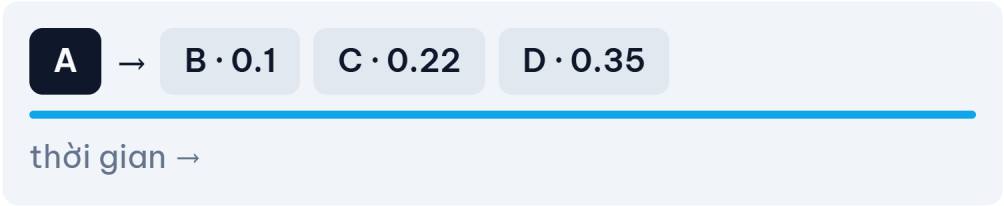
(c) Self-attention in Transformer

Hình 1(c), nguồn: bài báo gốc

Thách thức và giải pháp của SimpleDyG

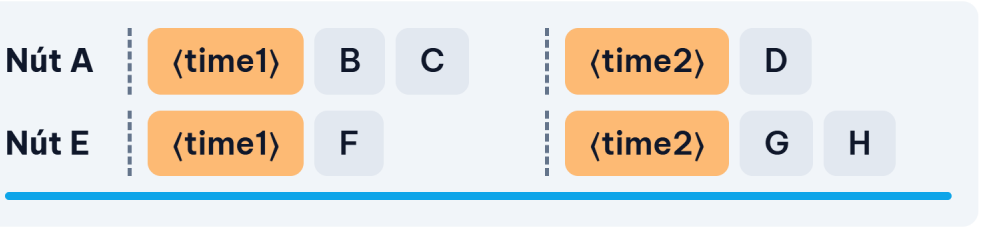
Thách thức 1 · Scalability → **Temporal ego-graph**

Attention theo cặp chỉ xử lý được đồ thị nhỏ; mỗi nút chỉ giữ chuỗi lịch sử của riêng mình.



Thách thức 2 · Căn chỉnh thời gian → **Temporal token**

10 tương tác trong 1 giờ khác 10 tương tác trong 1 ngày; token dùng chung đánh dấu time step.



2. RELATED WORK

Dynamic Graph Learning

Discrete-time

Cách làm: chuỗi snapshot, GNN kết hợp RNN hoặc attention

DySAT: graph attention + self-attention

EvolveGCN: RNN cập nhật tham số GCN

Điểm yếu: thiếu thông tin thời gian chi tiết

Continuous-time

Cách làm: xét từng sự kiện theo timestamp

Walk: temporal random walk, causal anonymous walk

Time encoding: TGAT, TGN, GraphMixer

Point process: DyRep, TREND

Điểm yếu: khó nắm phụ thuộc dài hạn

KHÁC BIỆT CỦA SIMPLEDYG

Xử lý phụ thuộc dài hạn nhờ Transformer, và giữ đầy đủ thứ tự thời gian của từng chuỗi.

Transformer cho đồ thị

STATIC

1. Trên đồ thị tĩnh (static)

Graphormer, SAN, Pure Transformers tích hợp tri thức cấu trúc (spatial, distance, centrality encoding) vào Transformer.

DYNAMIC

2. Trên đồ thị động (phức tạp)

Yu et al. (NeurIPS '23) cần thiết kế mô-đun **rất phức tạp** để mã hóa hàng xóm và khoảng thời gian.

SỰ KHÁC BIỆT VƯỢT TRỘI CỦA SIMPLEDYG

Đơn giản nhưng vượt trội

✓ **Đơn giản:** không thêm mô-đun phức tạp.

✓ **Vanilla Transformer:** giữ nguyên kiến trúc gốc.

✓ **Đổi mới ở đầu vào:** biến đổi đồ thị thành chuỗi token.

Chuỗi Input và Output

Token cấu trúc | Token thời gian | Token nút (nội dung)

Input x_i: lịch sử của ego-node v_i

⟨hist⟩ v_i ⟨time1⟩ a b ⟨time2⟩ c ⟨endofhist⟩

Các bước thời gian 1 đến T−1, mỗi bước mở đầu bằng token thời gian.

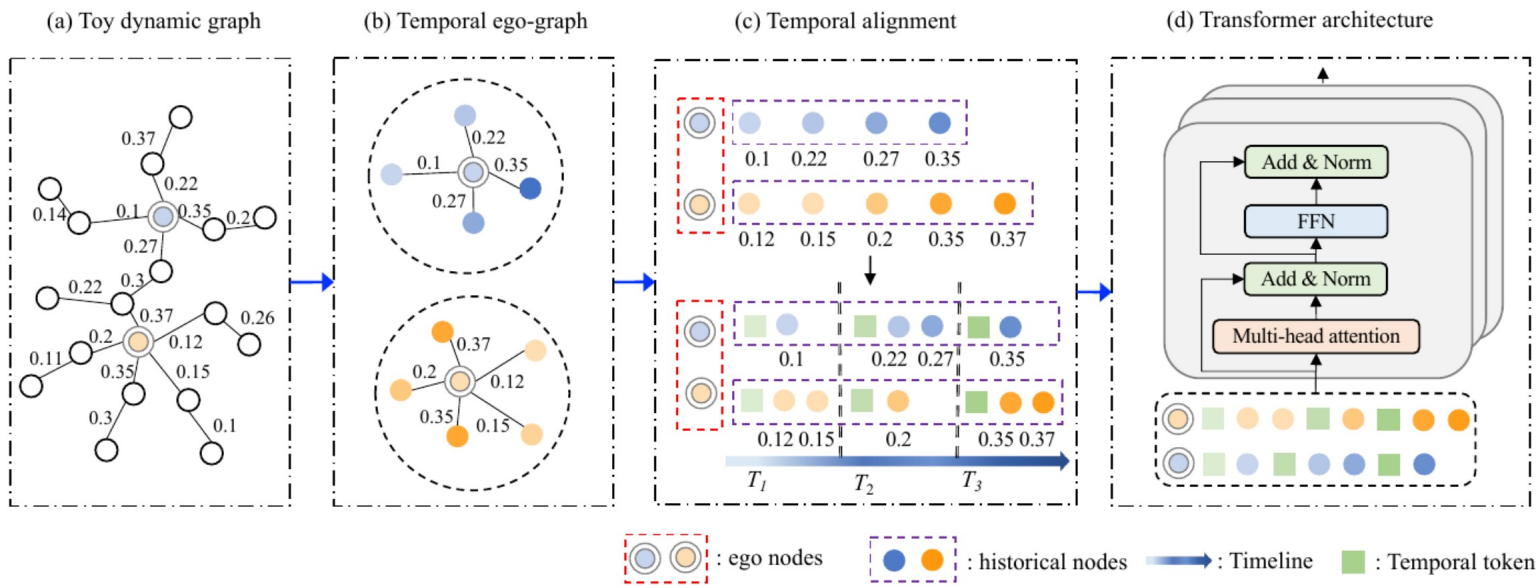
Output y_i: các nút liên kết ở bước T

⟨pred⟩ ⟨timeT⟩ d e ⟨endofpred⟩

Mô hình dừng dự đoán khi sinh ra ⟨endofpred⟩, nên tự quyết số nút.

Huấn luyện: ghép [x; y], dự đoán token kế tiếp (negative log-likelihood).

Tổng quan kiến trúc SimpleDyG



1. Đồ thị động → 2. Temporal Ego-graph → 3. Temporal Alignment → **4. Transformer**

KẾT LUẬN

Đóng góp chính và kết quả

1 **Khả thi**
Transformer gốc, đơn giản mà hiệu quả cho đồ thị động.

2 **Biến đổi đầu vào**
Temporal ego-graph và temporal token.

3 **Thực nghiệm**
4 tập dữ liệu thực: UCI, ML-10M, Hepth, MMConv.

Tập · Metric	GraphMixer	DySAT	SimpleDyG
UCI · Jaccard	0.042	0.010	**0.092**
UCI · NDCG@5	0.104	0.010	**0.104 (ngang bằng)**
ML-10M · NDCG@5	0.081	0.058	**0.138**
ML-10M · Jaccard	0.043	0.050	**0.131**

Thank you

Questions & Discussion

Yuxia Wu, Yuan Fang, Lizi Liao (2024). On the Feasibility of Simple Transformer for Dynamic Graph Modeling. Proceedings of the ACM Web Conference 2024 (WWW '24), Singapore. doi:10.1145/3589334.3645622